



Proyecto final Programación lineal

López Guerrero Andrea Patricia

Ruiz Madrigal Karen Daniela

Quiceno Banoy Juan Andrés

Piñeros Lozano Andrés Felipe

Pérez Ramírez Jhon Emerson

UNIVERSIDAD LIBRE

Facultad de ingeniería De sistemas

Bogotá D.C., Colombia

Agosto 2025



1. Introducción

En la actualidad, la creciente demanda de análisis de diversos tipos de información ha propiciado el desarrollo de múltiples modelos de procesamiento. Entre estos destaca el procesamiento asistido por inteligencia artificial, que posibilita la identificación de patrones complejos.

La presente investigación propone un modelo básico de inteligencia artificial implementado mediante una red neuronal fundamental, la cual será entrenada con un dataset de regresión lineal. Dicho conjunto de datos permite que la red aprenda la relación existente entre dos variables, la idea es que con datos simples es posible aplicar redes neuronales para identificar patrones y realizar predicciones.

2. Resumen

La necesidad de automatizar procesos en los sectores industriales y tecnológicos ha aumentado considerablemente debido al volumen de información y la demanda de procesamiento rápido. El presente trabajo propone una explicación detallada y el desarrollo de un modelo de Deep Learning, describiendo los diferentes algoritmos implementados mediante tecnologías de inteligencia artificial. Se analizará y propondrá un modelo básico de redes neuronales, comprendiendo su funcionamiento, comportamiento y los principios matemáticos que los fundamentan.

Para este propósito se utilizará un dataset de regresión lineal, con el cual la red neuronal será entrenada para identificar la relación entre dos variables. Este enfoque permitirá demostrar cómo, incluso con datos sencillos, es posible aplicar redes neuronales para reconocer patrones y realizar predicciones.

Los principales cambios:

- Corrección de errores gramaticales y ortográficos



- Mejora en la fluidez y coherencia
- Eliminación de redundancias
- Estructura más clara y académica
- Conclusión más precisa del objetivo

3. Abstract

Currently, the growing demand for analysis of various types of information has led to the development of multiple processing models. Among these, artificial intelligence-assisted processing stands out, enabling the identification of complex patterns. This approach based on machine learning provides autonomy, unlike traditional supervised models. The present research proposes a basic artificial intelligence model implemented through fundamental neural networks.

4. Estado del arte

En el presente artículo describiremos las generalidades de las RNA, modelos desarrollados de autoaprendizaje inspirados en la funcionalidad cerebral humana, una inteligencia computacional basada en comportamientos biológicos desarrollados para tareas específicas que requieran un alto nivel de procesamiento (Alvarado, M. (2015)).

Un sistema de procesamiento de neuronas (unidades de procesamiento) intercomunicadas con un estado de activación que procesan la información para transmitir una señal específica.

Las redes neuronales tienen un gran número de aplicaciones en sectores como lo son la medicina, las finanzas, industria agrícola, seguridad y educacional. A nuestro alrededor se están implementando modelos de IA artificial enfocados a varios campos, un ejemplo de un modelo de IA poco desarrollado son los asistentes virtuales desarrollados con respuestas automáticas para tareas ya predefinidas. El diagnóstico de enfermedades en la industria y, en general, en todos los campos se busca la optimización de procesos, llevar un control y aumentar el rendimiento de los resultados. Un modelo desarrollado con el foco



de una tarea específica, mejorando en cada procesamiento de su ejecución, dando resultados cada vez más precisos (Alvarado, M. (2015)).

Estos modelos de procesamiento son algoritmos complejos de desarrollo con un alto nivel de abstracción, capaces de realizar un autoaprendizaje, enfocados en la detección de patrones. Por medio, de sus capas de procesamiento, ajustando los pesos para mejorar sus predicciones con un análisis profundo de los datos ingresados. Haciendo un especial énfasis en los algoritmos de desarrollo implementados para el entrenamiento y desarrollo de la red neuronal.

Diversos autores han contribuido a consolidar el marco teórico y práctico de las redes neuronales artificiales. Warner y Misra (1996) plantean que las redes neuronales pueden entenderse como herramientas estadísticas avanzadas, capaces de capturar relaciones no lineales y complejas en los datos, superando en muchos casos a los modelos convencionales de regresión. De manera similar, Kuo y Reitsch (1996) compararon redes neuronales con métodos tradicionales de pronóstico, concluyendo que las RNA ofrecen mayor flexibilidad y precisión en contextos donde existen datos ruidosos o con alta variabilidad.

En cuanto al estado del arte, Kamel (2000) resalta que el desarrollo de redes neuronales ha mostrado progresos significativos en áreas como el reconocimiento de patrones, la clasificación y el procesamiento de señales, consolidándolas como herramientas de gran promesa dentro de la inteligencia computacional. Asimismo, Geman, Bienenstock y Doursat (1992) analizaron el dilema bias/variance en redes neuronales, demostrando que la capacidad de generalización depende del equilibrio entre la complejidad del modelo y el ajuste a los datos de entrenamiento.

Desde un enfoque probabilístico, Neal (1995) introdujo el aprendizaje bayesiano para redes neuronales, lo que permitió mejorar la estimación de incertidumbre en los resultados y otorgar un marco más robusto para la predicción. Igualmente, Grossberg (1988) estableció principios fundamentales sobre arquitecturas de redes neuronales no lineales, aportando bases matemáticas y teóricas para comprender mecanismos de autoorganización y aprendizaje.



En épocas más recientes, Glorot, Bordes y Bengio (2011) presentaron las redes neuronales profundas con funciones de activación rectificadoras dispersas (*Deep Sparse Rectifier Neural Networks*), avance que representó un hito para el desarrollo del *deep learning*, mejorando la eficiencia y estabilidad en el entrenamiento de modelos a gran escala.

5. Objetivos

5.1. Objetivo general

- Desarrollar un informe técnico y experimental de un modelo de Deep learning, que sea capaz de explicar modelos computacionales aplicados en programación lineal.

5.2. Objetivos específicos

- Recopilar información de fuentes confiables acerca de los principios, funcionamientos e implementación de la IA y Visión Artificial.
- Diseñar una arquitectura de Deep learning implementando algoritmos de computación, como lo son el gradiente y en su defecto backpropagación.
- Recopilar las pruebas y documentar el proceso de desarrollo explicando todos los procesos y algoritmos implementados.

Referencias

1. [B. Warner, M. Misra \(1996\).](#) *Understanding Neural Networks as Statistical Tools*
2. [Chin Kuo, A. Reitsch \(1996\).](#) *Neural Networks vs. Conventional Methods of Forecasting*
3. [M. Kamel \(2000\).](#) *Neural networks: the state of the art.* ICM'99. Proceedings. Eleventh International Conference on Microelectronics (IEEE Cat. No.99EX388)
4. [S. Geman, E. Bienenstock, R. Doursat \(1992\).](#) *Neural Networks and the Bias/Variance Dilemma.* Neural Computation
5. [Radford M. Neal \(1995\).](#) *Bayesian learning for neural networks*
6. [Radford M. Neal \(1995\).](#) *Bayesian Learning for Neural Networks*



7. [S. Grossberg \(1988\). *Nonlinear neural networks: Principles, mechanisms, and architectures*. Neural Networks](#)
8. [Xavier Glorot, Antoine Bordes, Yoshua Bengio \(2011\). *Deep Sparse Rectifier Neural Networks*. International Conference on Artificial Intelligence and Statistics](#)
- 9.

SECCION EXPLICATIVA

- 1) Tomaremos el dataset de la página
'<https://www.kaggle.com/datasets/andonians/random-linear-regression?resource=download>'
- 2) Crearemos una red neuronal de una sola capa la cual va a ser entrenada por el dataset, el modelo matemático que va a ser implementado es de una regresión lineal.
- 3) Entrenaremos la red neuronal ajustando los parámetros (pesos y sesgo) para que la predicción se acerque a los valores reales del dataset.
- 4) Validaremos el modelo utilizando el conjunto de prueba, verificando qué tan bien la red predice los nuevos datos.
- 5) Graficaremos los resultados para comparar los datos reales frente a las predicciones de la red neuronal.
- 6) Analizaremos la similitud entre los valores reales y los valores predichos, mostrando que la red aprendió la relación lineal entre las variables.
- 7) Concluiremos que incluso con una red neuronal sencilla y un dataset simple, es posible entrenar un modelo que aprenda patrones y realice predicciones.